



MACHINE LEARNING • INGENIERÍA DE DATOS

Videojuegos y Rendimiento Académico

Un análisis objetivo de cómo las rutinas de juego y descanso influyen en las notas de los estudiantes.

¿Por qué importa este análisis?

El debate

Existe una tensión constante entre el tiempo dedicado al ocio digital y el rendimiento escolar. Pero, ¿qué dicen los datos?

El problema

Necesitamos una forma **objetiva y cuantificable** de estimar el rendimiento académico a partir de rutinas de juego y sueño.

La fuente de datos

Dataset público de **Kaggle** con registros de estudiantes: horas de juego, horas de sueño, géneros preferidos y calificaciones finales.




Preparación de Datos: Ajustes Clave

- **Valores Faltantes y Duplicados:** El dataset original limpio, sin valores faltantes o duplicados, lo que simplificó el proceso inicial.
- **Distribuciones de Variables Clave:**


Horas de Estudio

Distribución casi uniforme (1-10 horas), con una kurtosis de ≈ -1.2 , indicando una falta de picos y colas pronunciadas.




Horas de Juego

También muestra una distribución uniforme (0-8 horas), lo que sugiere una variedad consistente de hábitos de juego entre los estudiantes.



Calificaciones

Promedio de 66.18, con una ligera asimetría hacia la izquierda (más estudiantes en el rango medio-alto), también con una kurtosis de ≈ -1.2 .



Hallazgos Críticos: Outliers en Calificaciones


Para asegurar la fiabilidad del análisis, realizamos ajustes exhaustivos en los datos brutos.

Calificaciones > 100

Se identificaron 134 estudiantes con calificaciones que superaban los 100 puntos (máx. 118.63). Esto es atípico y podría indicar un sistema de ponderación especial o un error en la entrada de datos.

Calificación = 0

Un estudiante obtuvo un 0, lo que podría representar abandono o un dato nulo disfrazado.



Preparando los datos para el modelo

Problemas del dataset original

- Valores "nulos" en registros de estudiantes
- Variables categóricas sin codificar (géneros de juegos)
- Escalas muy distintas entre horas de juego y calificaciones

Soluciones a aplicar con Pandas

- **One-Hot Encoding:** géneros como «RPG» o «FPS» se convierten en columnas numéricas
- **Normalización:** las horas se escalan para que ninguna variable domine por su magnitud

Enfoques de modelado

Se trata de un problema de **regresión**: predecir una nota numérica continua a partir de variables de comportamiento.



Regresión Lineal Múltiple

Modelo base, interpretable y rápido. Establece relaciones lineales entre las variables y la nota. Ideal como punto de partida y referencia de rendimiento mínimo.



Random Forest Regressor

Modelo basado en ensamble de árboles de decisión. Captura relaciones no lineales y es más robusto ante el ruido. Permite medir la **importancia de cada variable**.



Métricas clave

Los modelos se evaluarán mediante **RMSE** (error cuadrático medio) y **R² Score** (varianza explicada).